weather

November 24, 2023

[1]:
```
import numpy as np
import pandas as pd
import warnings
import matplotlib.pyplot as plt
warnings.filterwarnings("ignore")
```

[2]:
```
df=pd.read_csv(r"C:\Users\admin\OneDrive\Documents\weather_data.csv")
df.set_index('Date').sort_index()

columns_of_interest = ['TempAvgF','DewPointAvgF', 'HumidityAvgPercent',␣
 ↪'SeaLevelPressureAvgInches', 'VisibilityAvgMiles', 'WindAvgMPH',␣
 ↪'PrecipitationSumInches']
data = df[columns_of_interest]
events = df[['Events']].replace(' ', 'None')
```

Xem qua thành phần của bộ dữ liệu chúng ta sẽ dùng để phân tích

[3]:
```
events
```

[3]:
```
                    Events
0     Rain , Thunderstorm
1                     None
2                     None
3                     None
4                     None
…                      …
1314                  None
1315                  None
1316                  None
1317                  None
1318                  None

[1319 rows x 1 columns]
```

[4]:
```
data
```

[4]:
```
      TempAvgF DewPointAvgF HumidityAvgPercent SeaLevelPressureAvgInches  \
0           60           49                  75                      29.68
1           48           36                  68                      30.13
2           45           27                  52                      30.49
3           46           28                  56                      30.45
4           50           40                  71                      30.33
…          …            …                   …                       …
1314        89           67                  54                      29.97
1315        91           64                  54                       29.9
1316        92           64                  51                      29.86
1317        93           68                  48                      29.91
1318        88           61                  43                      29.97

     VisibilityAvgMiles WindAvgMPH PrecipitationSumInches
0                     7          4                   0.46
1                    10          6                      0
2                    10          3                      0
3                    10          4                      0
4                    10          2                      T
…                   …          …                      …
1314                 10          5                      0
1315                 10          5                      0
1316                 10          4                      0
1317                 10          4                      0
1318                 10          4                      0

[1319 rows x 7 columns]
```

Vẽ đồ thị thể hiện số lượng các sự kiện thời tiết đã xảy ra trong bộ dữ liệu

[5]:
```
ax = events.Events.value_counts().plot(kind='bar', figsize=(8,4), color = plt.
↪cm.Set2(range(len(events.Events.unique()))))
ax.set_title("Weather events in dataset", fontsize=18)
```

[5]:
```
Text(0.5, 1.0, 'Weather events in dataset')
```

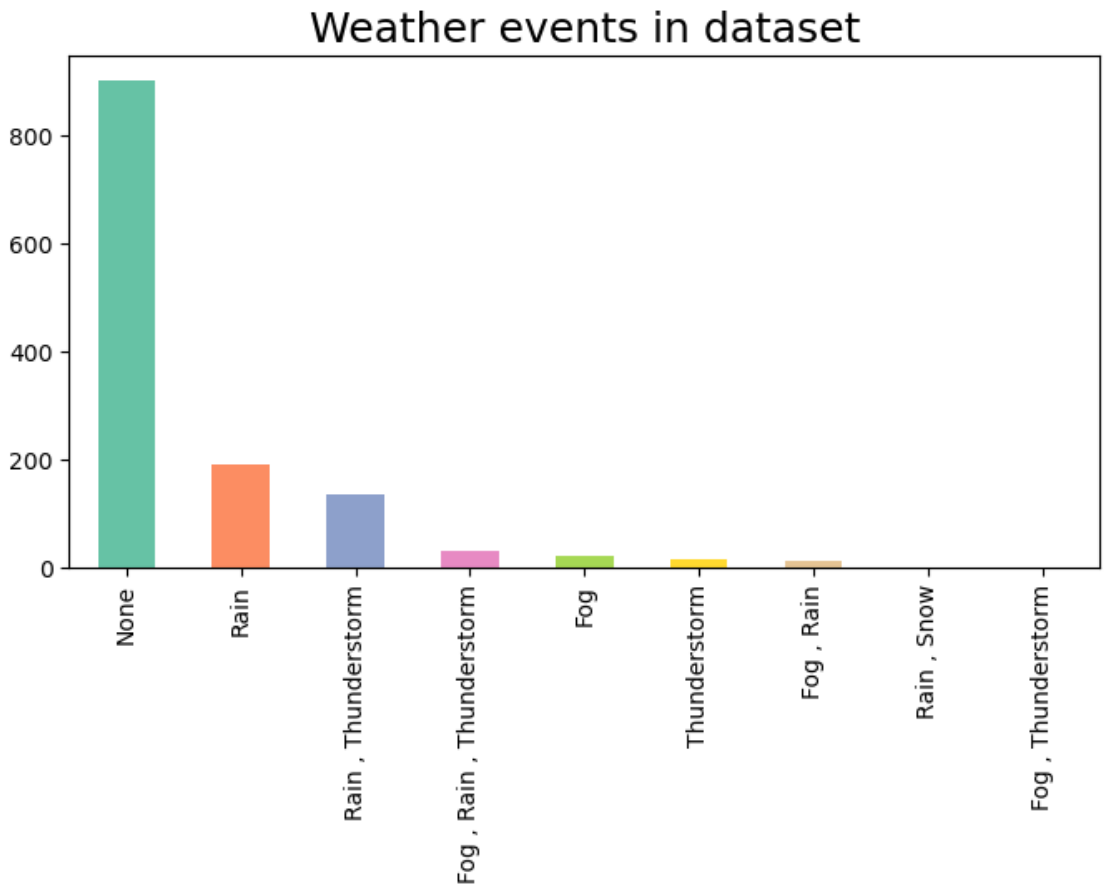

Lọc ra những sự kiện thời tiết đơn lẻ

[6]:
```
unique_events = set()
for value in events.Events.value_counts().index:
    splitted = [x.strip() for x in value.split(',')]
    unique_events.update(splitted)
unique_events
```

[6]:
```
{'Fog', 'None', 'Rain', 'Snow', 'Thunderstorm'}
```

Gán giá trị True cho các sự kiện thời tiết xảy ra tương ứng với từng hàng, ngược lại thì False

[7]:
```
single_events = pd.DataFrame()
for event_type in unique_events:
    event_occurred = events.Events.str.contains(event_type)
    single_events = pd.concat([single_events, pd.DataFrame(data={event_type:␣
 ↪event_occurred.values})], join='outer', axis=1)
single_events
```

[7]:

	Thunderstorm	None	Fog	Rain	Snow
0	True	False	False	True	False
1	False	True	False	False	False
2	False	True	False	False	False
3	False	True	False	False	False
4	False	True	False	False	False
…	…	…	…	…	…
1314	False	True	False	False	False
1315	False	True	False	False	False
1316	False	True	False	False	False
1317	False	True	False	False	False
1318	False	True	False	False	False

[1319 rows x 5 columns]

Vẽ đồ thị thể hiện số lượng của từng sự kiện thời tiết riêng lẻ trong bộ dữ liệu

[8]:
```
ax = single_events.sum().sort_values(ascending=False).plot.bar(figsize=(8,5),␣
↪color = plt.cm.Set2(range(len(events.Events.unique()))))
ax.set_title("Single weather events in dataset", fontsize=18)
```

[8]: Text(0.5, 1.0, 'Single weather events in dataset')

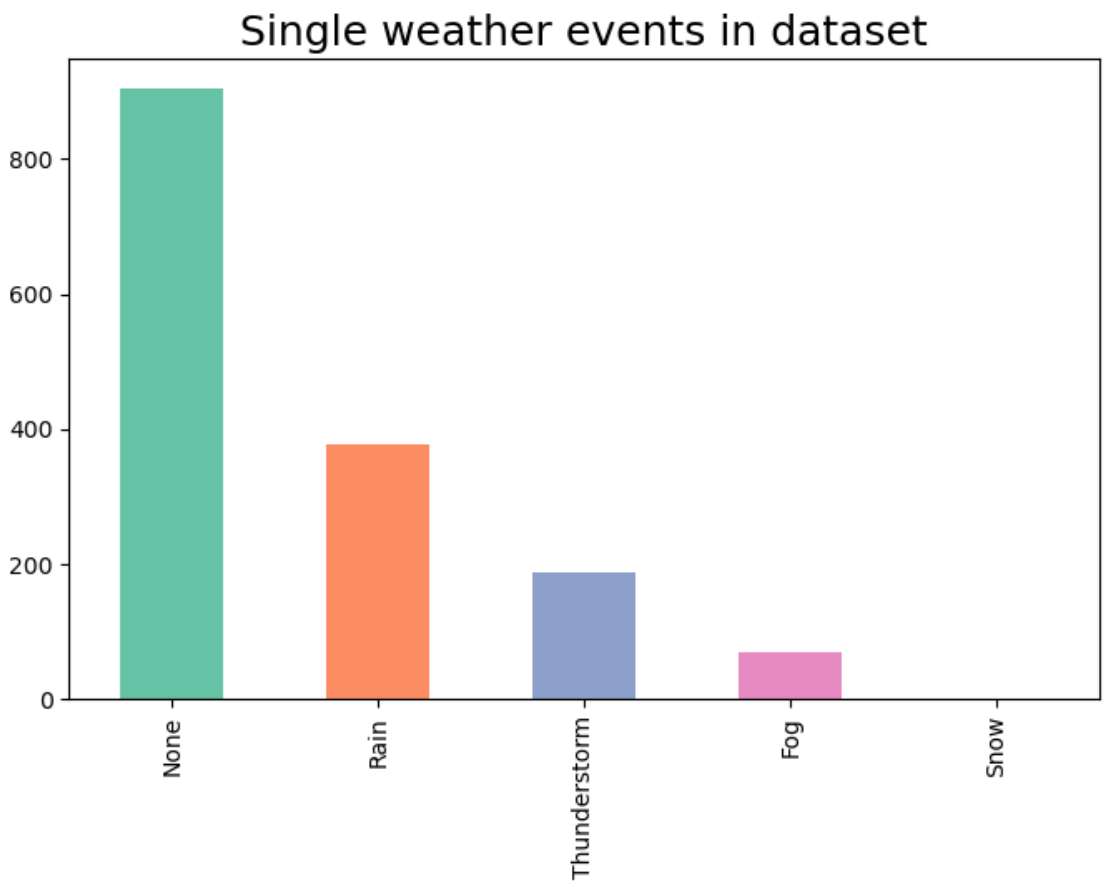

Trong bộ dữ liệu đang sử dụng, có thể thấy ở cột PrecipitationSumInches có các giá trị T bên cạnh những số cụ thể. Điều này có thể hiểu là vào ngày hôm đó có mưa nhưng không biết cụ thể là bao nhiêu.

[9]:
```
precipitation = data[pd.to_numeric(data.PrecipitationSumInches,␣
 ↪errors='coerce').isnull()].PrecipitationSumInches.value_counts()
precipitation
```

[9]:
```
T    124
Name: PrecipitationSumInches, dtype: int64
```

Kiểm tra xem bộ dữ liệu được sử dụng có bao nhiêu hàng không phải là số.

[10]:
```
def isColumnNotNumeric(columns_of_interest, data):
    result = np.zeros(data.shape[0], dtype=bool)
    for column_name in columns_of_interest:
        result = result | pd.to_numeric(data[column_name], errors='coerce').
 ↪isnull()
    return result

def getDataFrameWithNonNumericRows(dataFrame):
    return data[isColumnNotNumeric(columns_of_interest, data)]

non_numeric_rows_count = getDataFrameWithNonNumericRows(data).shape[0]

print("Non numeric rows: {0}".format(non_numeric_rows_count))
```

```
Non numeric rows: 134
```

Chuyển đổi các dòng có T trong cột PrecipitationSumInches thành số 0. Đồng thời, tạo một cột mới tên PrecipitationTrace để lưu trữ các giá trị T này (gán 1 cho những dòng có T, 0 cho những dòng còn lại)

[11]:
```
def numberOrZero(value):
    try:
        parsed = float(value)
        return parsed
    except:
        return 0

#Find rows indices with "T" values
has_precipitation_trace_series = isColumnNotNumeric(['PrecipitationSumInches'],␣
 ↪data).astype(int)
data = data.assign(PrecipitationTrace=has_precipitation_trace_series.values)
data['PrecipitationSumInches'] = data['PrecipitationSumInches'].
 ↪apply(numberOrZero)
```

```
data.iloc[0:10,:]
```

[11]:

	TempAvgF	DewPointAvgF	HumidityAvgPercent	SeaLevelPressureAvgInches	VisibilityAvgMiles	WindAvgMPH	PrecipitationSumInches	PrecipitationTrace
0	60	49	75	29.68	7	4	0.46	0
1	48	36	68	30.13	10	6	0.00	0
2	45	27	52	30.49	10	3	0.00	0
3	46	28	56	30.45	10	4	0.00	0
4	50	40	71	30.33	10	2	0.00	1
5	48	36	63	30.4	9	3	0.00	0
6	53	39	65	30.39	9	1	0.00	1
7	51	39	64	30.17	10	2	0.00	1
8	50	41	76	30.1	10	5	0.00	0
9	40	26	60	30.33	10	5	0.00	0

Từ các output trên, có thể thấy, ngoài cột T thì có nhiều cột khác chứa giá trị không phải số và đã được chuyển thành null. Vì thế, phải cân nhắc xử lí để mô hình chạy hiệu quả.

[12]:
```
getDataFrameWithNonNumericRows(data)
```

[12]:

	TempAvgF	DewPointAvgF	HumidityAvgPercent	SeaLevelPressureAvgInches	VisibilityAvgMiles	WindAvgMPH	PrecipitationSumInches	PrecipitationTrace
174	79	-	75	29.95	-	4	0.0	0
175	92	-	77	29.93				
176	83	-	-	29.9				
177	84	-	72	29.99				
596	89	-	65	-				
597	90	-	62	-				
598	90	-	-	-				
638	82	63	60	29.96				
639	84	64	57	29.95				
741	46	33	60	30.48				
742	45	34	77	30.42				
953	88	73	66	29.97				

175	-	6	0.0	0
176	-	9	0.0	0
177	-	8	0.0	1
596	-	-	0.0	0
597	-	6	0.0	0
598	-	-	0.0	0
638	-	3	0.0	0
639	-	4	0.0	0
741	-	8	0.0	1
742	-	2	0.2	0
953	-	6	0.0	0

[13]:
```
row_indices_for_missing_values = getDataFrameWithNonNumericRows(data).index.
  ↪values
data_prepared = data.drop(row_indices_for_missing_values)
events_prepared = single_events.drop(row_indices_for_missing_values)
print("Data rows: {0}, Events rows: {1}".format(data_prepared.shape[0],␣
  ↪events_prepared.shape[0]))
```

```
Data rows: 1307, Events rows: 1307
```

Vì mô hình của học máy không giám sát nhóm sử dụng được chạy trên các dữ liệu dạng số. Vì thế, phải kiểm tra xem loại dữ liệu của các cột và ép kiểu nếu cần.

[14]:
```
data_prepared.dtypes
```

[14]:
```
TempAvgF                    int64
DewPointAvgF               object
HumidityAvgPercent         object
SeaLevelPressureAvgInches  object
VisibilityAvgMiles         object
WindAvgMPH                 object
PrecipitationSumInches    float64
PrecipitationTrace          int32
dtype: object
```

[15]:
```
data_prepared = data_prepared.apply(pd.to_numeric)
data_prepared.dtypes
```

[15]:
```
TempAvgF                    int64
DewPointAvgF                int64
HumidityAvgPercent          int64
SeaLevelPressureAvgInches  float64
VisibilityAvgMiles          int64
WindAvgMPH                  int64
PrecipitationSumInches    float64
PrecipitationTrace          int32
dtype: object
```

[16]:
```
data_prepared
```

[16]:
```
      TempAvgF  DewPointAvgF  HumidityAvgPercent  SeaLevelPressureAvgInches  \
0           60            49                  75                      29.68
1           48            36                  68                      30.13
2           45            27                  52                      30.49
3           46            28                  56                      30.45
4           50            40                  71                      30.33
…          …             …                   …                       …
1314        89            67                  54                      29.97
1315        91            64                  54                      29.90
1316        92            64                  51                      29.86
1317        93            68                  48                      29.91
1318        88            61                  43                      29.97

      VisibilityAvgMiles  WindAvgMPH  PrecipitationSumInches  \
0                      7           4                    0.46
1                     10           6                    0.00
2                     10           3                    0.00
3                     10           4                    0.00
4                     10           2                    0.00
…                    …           …                    …
1314                  10           5                    0.00
1315                  10           5                    0.00
1316                  10           4                    0.00
1317                  10           4                    0.00
1318                  10           4                    0.00

      PrecipitationTrace
0                      0
1                      0
2                      0
3                      0
4                      1
…                    …
1314                   0
1315                   0
1316                   0
1317                   0
1318                   0

[1307 rows x 8 columns]
```

Bắt đầu chuẩn hóa dữ liệu để huấn luyện mô hình

[17]:
```
from sklearn import preprocessing
data_values = data_prepared.values #returns a numpy array
```

```
min_max_scaler = preprocessing.MinMaxScaler()

data_prepared = pd.DataFrame(min_max_scaler.fit_transform(data_prepared),␣
 ↪columns=data_prepared.columns, index=data_prepared.index)
```

[18]:
```
data_prepared.head()
```

[18]:

	TempAvgF	DewPointAvgF	HumidityAvgPercent	SeaLevelPressureAvgInches	\
0	0.484375	0.602941	0.685714	0.109244	
1	0.296875	0.411765	0.585714	0.487395	
2	0.250000	0.279412	0.357143	0.789916	
3	0.265625	0.294118	0.414286	0.756303	
4	0.328125	0.470588	0.628571	0.655462	

	VisibilityAvgMiles	WindAvgMPH	PrecipitationSumInches	PrecipitationTrace
0	0.625	0.272727	0.088462	0.0
1	1.000	0.454545	0.000000	0.0
2	1.000	0.181818	0.000000	0.0
3	1.000	0.272727	0.000000	0.0
4	1.000	0.090909	0.000000	1.0

[19]:
```
events_prepared.head()
```

[19]:

	Thunderstorm	None	Fog	Rain	Snow
0	True	False	False	True	False
1	False	True	False	False	False
2	False	True	False	False	False
3	False	True	False	False	False
4	False	True	False	False	False

Chia dữ liệu thành 2 tập riêng biệt để huấn luyện và kiểm thử

[20]:
```
from sklearn.model_selection import train_test_split

random_state = 42
X_train, X_test = train_test_split(data_prepared, test_size=0.2,␣
 ↪random_state=random_state)
y_train, y_test = train_test_split(events_prepared, test_size=0.2,␣
 ↪random_state=random_state)

clusters_count = len(unique_events)
```

Sử dụng những thuật toán phân cụm và so sánh với kết quả thực tế. Từ đó, đưa ra thuật toán cho kết quả gần với thực tế nhất.

[21]:
```
from sklearn.cluster import KMeans
warnings.filterwarnings("ignore")
```

```
kmeans = KMeans(n_clusters=clusters_count).fit(X_train)

resultDf = pd.DataFrame(kmeans.labels_)
ax = resultDf.iloc[:,0].value_counts().plot.bar(color = plt.cm.
 ↪Set2(range(len(events.Events.unique()))))
ax.set_title("K-Means clustering", fontsize=16)
```

[21]: Text(0.5, 1.0, 'K-Means clustering')

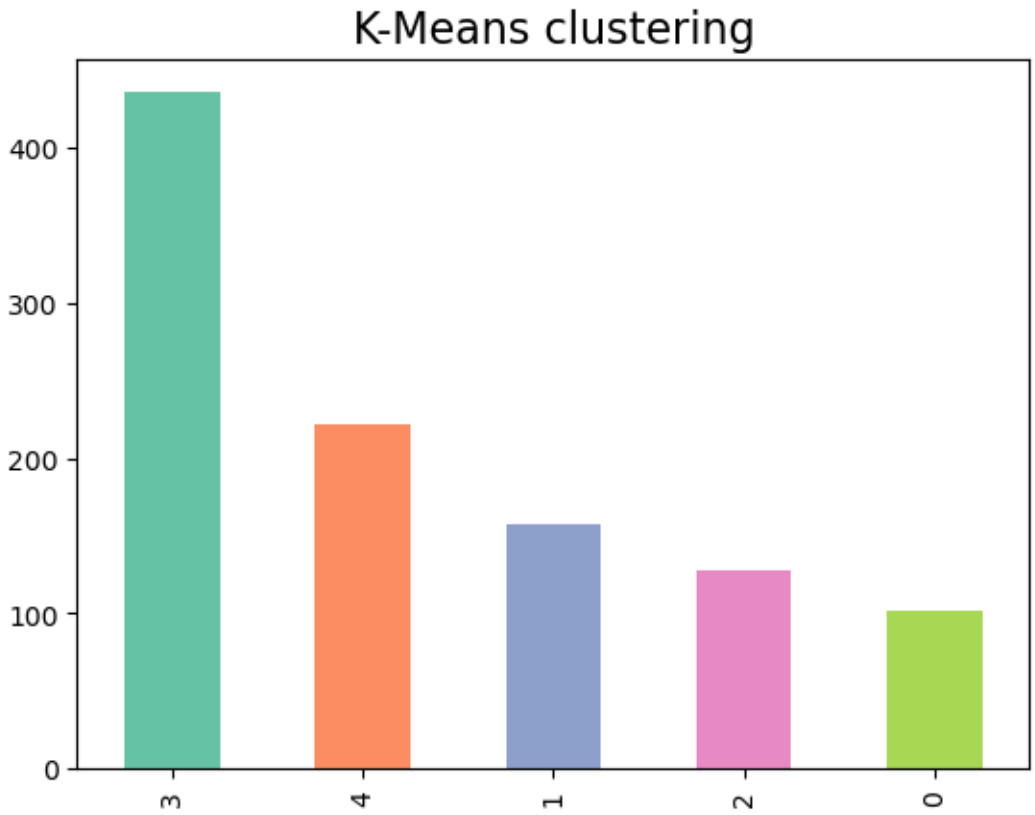

[22]:
```
from sklearn.cluster import SpectralClustering
warnings.filterwarnings("ignore")
sc = SpectralClustering(n_clusters=clusters_count).fit(X_train)
resultDf2 = pd.DataFrame(sc.labels_)
ax = resultDf2.iloc[:,0].value_counts().plot.bar(color = plt.cm.
 ↪Set2(range(len(events.Events.unique()))))
ax.set_title("Spectral Clustering", fontsize=16)
```

[22]: Text(0.5, 1.0, 'Spectral Clustering')

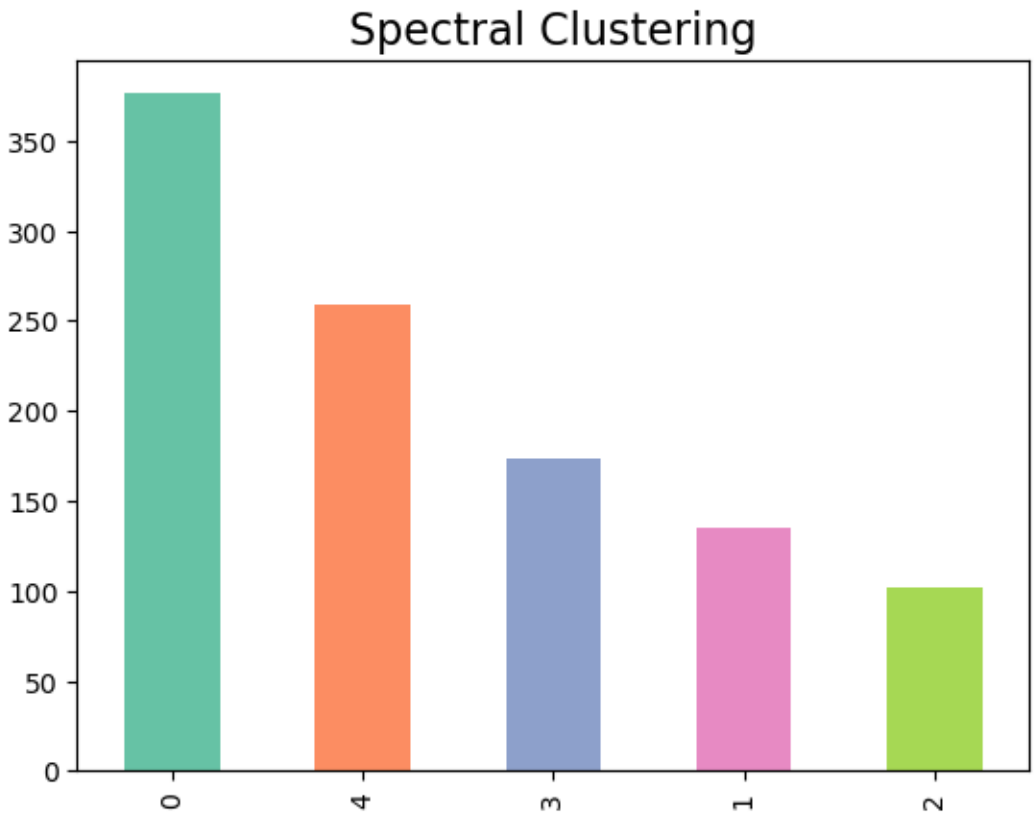

[23]:
```
from sklearn.cluster import DBSCAN
dbscan = DBSCAN(eps=0.25, min_samples=4).fit(X_train)
resultDf = pd.DataFrame(dbscan.labels_)
ax = resultDf.iloc[:,0].value_counts().plot.bar(color = plt.cm.
 ↪Set2(range(len(events.Events.unique()))))
ax.set_title("DBSCAN", fontsize=16)
```

[23]:
```
Text(0.5, 1.0, 'DBSCAN')
```

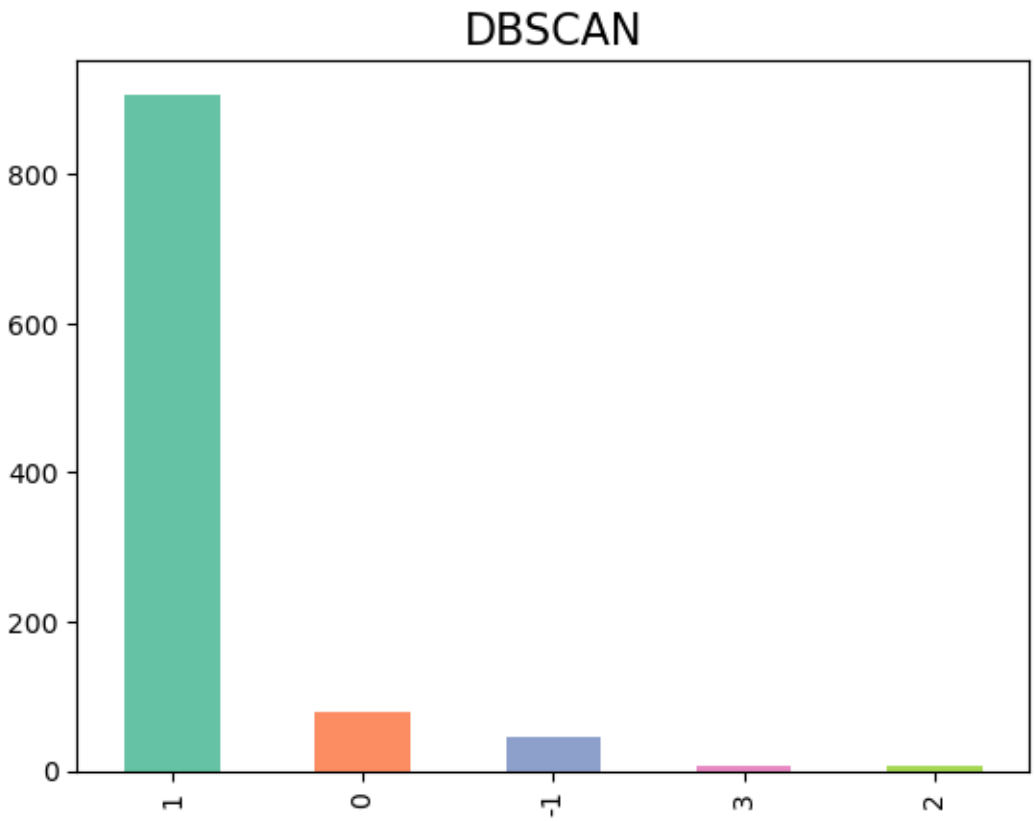

[24]:
```
from sklearn.cluster import AgglomerativeClustering

ac = AgglomerativeClustering(n_clusters=clusters_count, linkage="average").
 ↪fit(X_train)
resultDf = pd.DataFrame(ac.labels_)
ax = resultDf.iloc[:,0].value_counts().plot.bar(color = plt.cm.
 ↪Set2(range(len(events.Events.unique()))))
ax.set_title("Agglomerative Clustering", fontsize=16)
```

[24]:
```
Text(0.5, 1.0, 'Agglomerative Clustering')
```

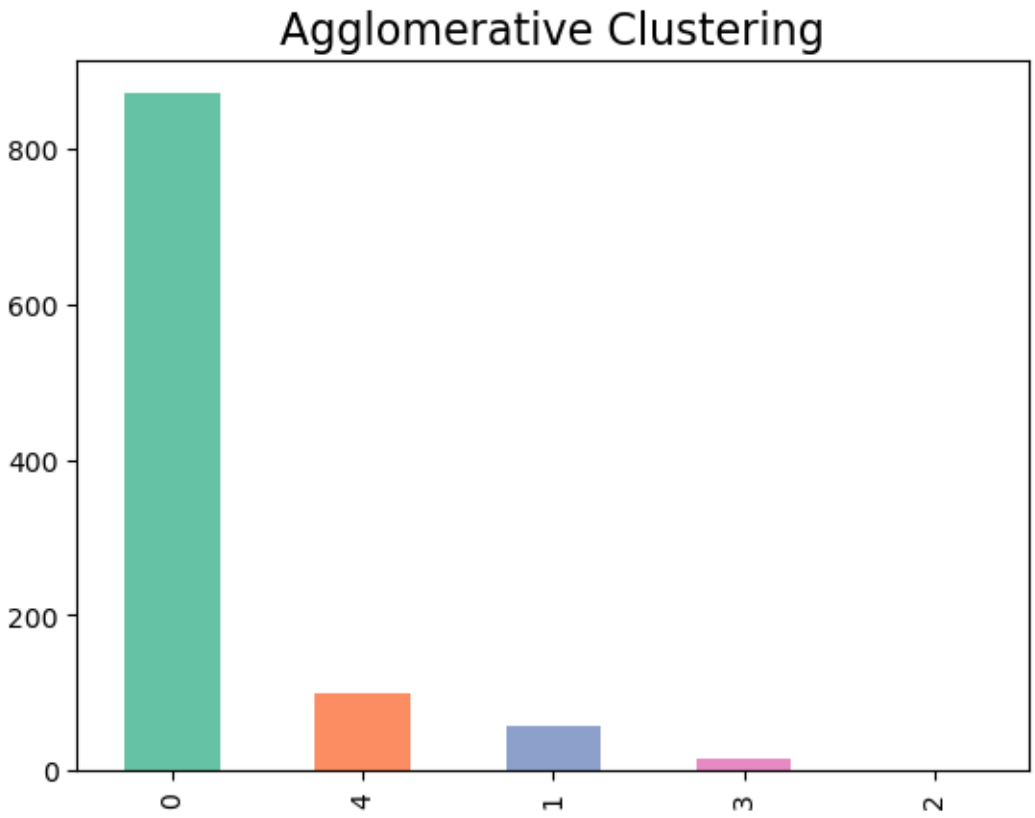

Có thể thấy, thuật toán phân cụm Agglomerative đem lại kết quả phân cụm gần với thực tế nhất.

[25]:
```
fig, ax = plt.subplots(1, 2, figsize=(15, 5))
events_prepared.sum().sort_values(ascending=False).plot.bar(ax=ax[0],␣
 ↪title="Real events that happened", color = plt.cm.Set2(range(len(events.
 ↪Events.unique()))))
resultDf.iloc[:,0].value_counts().plot.bar(ax=ax[1], title="Bar obtained from␣
 ↪agglomerative clustering", color = plt.cm.Set2(range(len(events.Events.
 ↪unique()))))
```

[25]:
```
<Axes: title={'center': 'Bar obtained from agglomerative clustering'}>
```

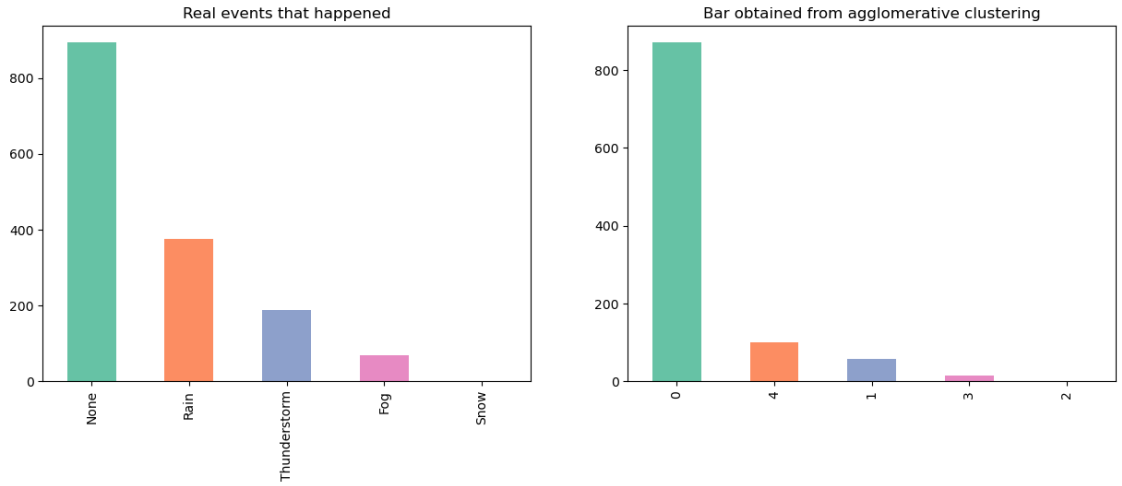

Thực hiện gán tên cụm vào tên sự kiện thời tiết tương ứng. Sau đó, sử dụng lý thuyết phân cụm của thuật toán Agglomerative để xem rằng liệu 1 ngày có thể có 2 sự kiện thời tiết hay không.

[26]:
```
event_names_ordered = events_prepared.sum().sort_values(ascending=False).index
clusters_ordered = resultDf.iloc[:,0].value_counts().index
cluster_category_mapping = {}
for i in range(clusters_count):
    cluster_category_mapping.update({clusters_ordered[i]:
 ↪event_names_ordered[i]})
cluster_category_mapping
```

[26]:
```
{0: 'None', 4: 'Rain', 1: 'Thunderstorm', 3: 'Fog', 2: 'Snow'}
```

[27]:
```
#tọa độ tâm từng cụm
cluster_centers_mapping = {}
for key in cluster_category_mapping:
    cluster_indices = resultDf.loc[resultDf[0] == key].index
    cluster_data = X_train.iloc[cluster_indices]
    mean = cluster_data.mean(axis=0).values
    #print("\n" + cluster_category_mapping[key])
    #print(mean)
    cluster_centers_mapping.update({key:mean})
cluster_centers_mapping
```

[27]:
```
{0: array([0.66684626, 0.71558485, 0.53737274, 0.39408867, 0.92715517,
        0.36185998, 0.01333112, 0.        ]),
 4: array([0.66259282, 0.7603378 , 0.62192362, 0.39995008, 0.9220297 ,
        0.39423942, 0.        , 1.        ]),
 1: array([0.37553879, 0.59077079, 0.81453202, 0.46479281, 0.47844828,
        0.40125392, 0.06999337, 0.        ]),
 3: array([0.690625  , 0.88431373, 0.85142857, 0.28403361, 0.46666667,
```

```
        0.44242424, 0.59641026, 0.        ]),
 2: array([0.015625  , 0.05882353, 0.3       , 0.83193277, 1.        ,
        0.36363636, 0.        , 1.        ])}
```

[28]:
```
#tính khoảng cách từ 1 điểm đến tâm từng cụm
def get_distances_from_cluster(data_frame):
    cluster_distance = np.zeros((data_frame.shape[0], clusters_count))
    #khoảng cách euclidean
    for i in range(data_frame.shape[0]):
        for key in cluster_category_mapping:
            dist = np.linalg.norm(data_frame.iloc[[i]].
 ↪values[0]-cluster_centers_mapping[key])
            cluster_distance[i,key] = dist
            #print(dist)
    column_names = [cluster_category_mapping[k] for k in␣
 ↪cluster_category_mapping]
    #column_names

    return pd.DataFrame(cluster_distance, index=data_frame.index,␣
 ↪columns=column_names)

distancesDf = get_distances_from_cluster(X_train)
distancesDf.sort_index().head()
```

[28]:

	None	Rain	Thunderstorm	Fog	Snow
0	0.503997	0.439705	1.530869	0.701142	1.120684
1	0.504285	0.608979	1.188391	1.063296	1.128684
2	0.768810	0.867572	1.068494	1.329796	1.294182
3	0.705968	0.799183	1.070004	1.269659	1.251355
4	1.153381	1.208659	0.693316	1.501303	0.599369

[29]:
```
def classify_events(distances_dataFrame):
    return distances_dataFrame.apply(lambda x: x<x.min()*1.01, axis=1)

#xem giá trị  dự đoán có đúng vs gtri thực tế
def check_accuracy(X, y):
    comparison = X == y
    val_counts = comparison.all(axis=1).value_counts()
    percentageCorrect = val_counts.at[True] / X.shape[0] * 100
    return percentageCorrect
```

Đánh giá mô hình phân cụm dựa trên tỷ lệ giữa số dòng dự báo đúng và tổng số dòng của 2 tập X_train và X_test

[30]:
```
classification_result = classify_events(distancesDf)
X_train_col_ordered = classification_result.
 ↪reindex(sorted(classification_result.columns), axis=1)
```

```
y_train_col_ordered = y_train.reindex(sorted(y_train.columns), axis=1)
a = check_accuracy(X_train_col_ordered, y_train_col_ordered)

fig, ax = plt.subplots(1, 2, figsize=(15, 5))
y_train_col_ordered.sum().plot.bar(ax=ax[0], title="Real events that happened",␣
 ↪color = plt.cm.Set2(range(len(events.Events.unique()))))
ax = X_train_col_ordered.sum().plot.bar(ax=ax[1], title="Predicted events",␣
 ↪color = plt.cm.Set2(range(len(events.Events.unique()))))
#resultDf.iloc[:,0].value_counts().plot.bar(ax=ax[1], title="Histogram obtained␣
 ↪from agglomerative clustering")
print(f'Chỉ số Accuracy của mô hình là {a}')
```

```
Chỉ số Accuracy của mô hình là 64.97607655502392
```

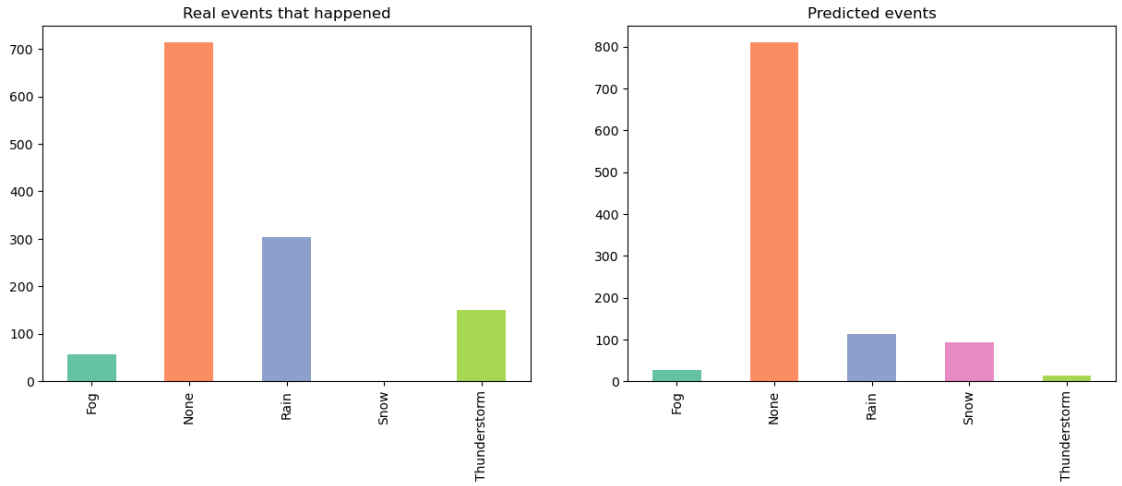

[31]:
```
distancesDf = get_distances_from_cluster(X_test)
classification_result = classify_events(distancesDf)
X_test_col_ordered = classification_result.reindex(sorted(classification_result.
 ↪columns), axis=1)
y_test_col_ordered = y_test.reindex(sorted(y_train.columns), axis=1)
a = check_accuracy(X_test_col_ordered, y_test_col_ordered)

fig, ax = plt.subplots(1, 2, figsize=(15, 5))
y_test_col_ordered.sum().plot.bar(ax=ax[0], title="Real events that happened",␣
 ↪color = plt.cm.Set2(range(len(events.Events.unique()))))
X_test_col_ordered.sum().plot.bar(ax=ax[1], title="Predicted events", color =␣
 ↪plt.cm.Set2(range(len(events.Events.unique()))))
print(f'Chỉ số Accuracy của mô hình là {a}')
```

```
Chỉ số Accuracy của mô hình là 70.22900763358778
```

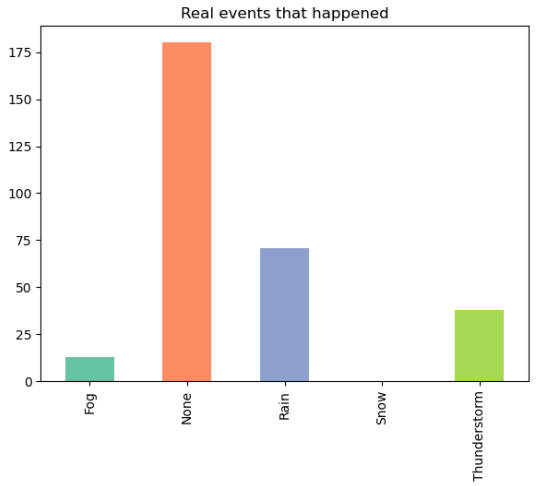
Real events that happened
175
150
125
100
75
50
25
0
Fog
None
Rain
Snow
Thunderstorm

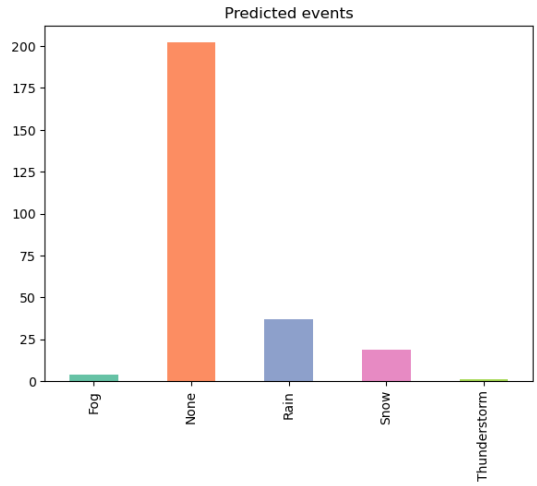
Predicted events
200
175
150
125
100
75
50
25
0
Fog
None
Rain
Snow
Thunderstorm